TD n°1 — Qualité des données
Criminalité à Cambridge (2009–2024)

ABRAURE Axel

EPSI — 2025-2026

Contexte

En tant que consultant pour le service « Sécurité » de la ville de Cambridge, nous avons réalisé un audit complet de qualité sur les données de crimes déclarés entre 2009 et 2024, issues de systèmes opérationnels hétérogènes.

L'objectif est d'évaluer la fiabilité du dataset, d'appliquer des règles de traitement adaptées, et de produire des indicateurs d'aide à la décision — dont une carte choroplèthe des crimes par quartier.

Livrables produits

Livrable	Statut
crime_reports_clean.csv — Dataset nettoyé	✅Produit
map.html — Carte choroplèthe interactive	✅Produit
tests/test_quality.py — 20 tests pytest	✅20/20 passés
logs/app.log — Journalisation	✅Produit
README.md — Documentation	✅Produit

ABRAURE Axel — 2025-2026

1. Profilage et exploration

1.1 Dimensions du dataset

Métrique	Valeur
Nombre de lignes	10 506
Nombre de colonnes	7
Taille du fichier	~1.5 Mo
Période couverte	2009 – 2024

1.2 Types des colonnes

Colonne	Type brut	Remarque
File Number	str	Format AAAA-NNNNN
Date of Report	str	DateTime attendu — à parser
Crime Date Time	str	Plage ou instant — à parser
Crime	str	Catégorie — 525 nulls
Reporting Area	str	Numérique attendu — valeurs aberrantes
Neighborhood	str	Catégorie référentielle — 717 nulls
Location	str	Adresse — non utilisée dans analyses

1.3 Valeurs manquantes

Colonne	Nb manquants	% manquants	Criticité
File Number	0	0.00 %	—
Date of Report	0	0.00 %	—
Crime Date Time	0	0.00 %	—
Crime	525	5.00 %	□ Haute
Reporting Area	26	0.25 %	Faible
Neighborhood	717	6.82 %	□ Haute
Location	239	2.27 %	Faible

1.4 Problèmes de qualité identifiés

- **Doublons exacts :** 204 lignes strictement identiques détectées (1,94% du dataset)
- **Valeurs manquantes :** Crime : 5,00 % — Neighborhood : 6,82 % — Location : 2,27 %
- **Neighborhood invalide :** Valeurs hors référentiel officiel : not_specified, ???, Cambrigeport, N-A, Unknown
- **Reporting Area non conforme :** Valeurs négatives (ex : -12) ou non numériques incompatibles avec un code de zone

ABRAURE Axel — 2025-2026

- **Incohérences temporelles :** 3,79 % des lignes ont une Date of Report antérieure au début de Crime Date Time

1.5 Dictionnaire des données

Nom	Type	Définition	Exemple	Remarque
File Number	str	Identifiant unique du dossier (AAAA-NNNNN)	2016-02477	Doublons détectés
Date of Report	str→datetime	Date/heure du signalement police	04/14/2016 07:11 PM	Dates invalides présentes
Crime Date Time	str→plage	Fenêtre temporelle estimée du crime	04/13/2016 20:00 - 04/14/2016 06:30	Instant ou plage
Crime	str (cat.)	Type de crime déclaré	Larceny from MV	~5 % de nulls
Reporting Area	str→int	Code zone de patrouille (1–4 chiffres)	403	Valeurs négatives / non num.
Neighborhood	str (cat.)	Quartier officiel de Cambridge (réf. 13 valeurs)	Cambridgeport	~7 % NaN + valeurs parasites
Location	str	Adresse approximative du lieu du crime	100 HARVARD ST, Cambridge, MA	~2 % manquants — non utilisé

ABRAURE Axel — 2025-2026

2. Audit de la qualité

Huit indicateurs ont été définis et calculés sur le dataset brut, avec des seuils d'acceptation pour les plus critiques.

2.1 Indicateurs et seuils d'acceptation

Indicateur	Valeur	Seuil	Type seuil	Statut
Complétude File Number	100.00 %	≥ 99 %	Min	✓
Complétude Crime	95.00 %	≥ 95 %	Min	✓
Complétude Neighborhood	93.18 %	≥ 95 %	Min	✗
Unicité File Number	95.18 %	≥ 99 %	Min	✗
Taux doublons exacts	1.94 %	≤ 1 %	Max	✗
Taux dates invalides	0.98 %	≤ 1 %	Max	✓
Taux incohérences temporelles	3.79 %	≤ 1 %	Max	✗
Taux Reporting Area non conformes	1.04 %	≤ 1 %	Max	✗

Bilan avant nettoyage : 5 indicateurs sur 8 ne respectent pas leur seuil d'acceptation. Les anomalies les plus critiques sont les incohérences temporelles (3,79 %) et les doublons exacts (1,94 %).

ABRAURE Axel — 2025-2026

3. Traitement et nettoyage

3.1 Règles appliquées

Anomalie	Décision	Lignes	Justification
Doublons exacts	Suppression (1ère occurrence conservée)	204	Identifiant unique — double saisie sans valeur analytique
Crime null	Suppression	525	Ligne inexploitable sans type de crime
Date of Report invalide	Suppression	94	Date structurante — non inférable
Date of Report < Crime Start	Suppression	380	Incohérence logique irréparable
Reporting Area invalide	Mise à NaN → Suppression	117	Erreur de saisie — valeur correcte non inférable
Neighborhood hors référentiel	Mise à NaN → Suppression	817	Seuls les 13 quartiers officiels ont une signification cartographique

3.2 Résultat du nettoyage

Métrique	Avant	Après	Évolution
Nombre de lignes	10 506	8 369	-2 137 (-20,3 %)
Doublons exacts	204	0	✓Éliminés
Crimes null	525	0	✓Éliminés
Neighborhoods invalides	210+	0	✓Éliminés

3.3 Enrichissement — reporting_area_group

Une nouvelle colonne reporting_area_group a été créée en extrayant le groupe de centaines de Reporting Area (ex : 602 → 6 ; 1109 → 11). Cette colonne prépare la granularité nécessaire pour des analyses cartographiques à l'échelle des zones de patrouille.

- **Règle :** Extraction : reporting_area_group = Reporting Area // 100
- **Validation :** 19 valeurs aberrantes neutralisées (groupe ≤ 0 ou > 20)
- **Résultat :** Plage finale : 1 à 13 (cohérent avec la géographie de Cambridge)

ABRAURE Axel — 2025-2026

4. Monitoring de la qualité des données

4.1 Comparaison avant / après nettoyage

Indicateur	Avant	Après	Δ	Significatif
Complétude File Number	100.00 %	100.00 %	0.00 %	—
Complétude Crime	95.00 %	100.00 %	+5.00 %	⚡ Oui
Complétude Neighborhood	93.18 %	100.00 %	+6.82 %	⚡ Oui
Unicité File Number	95.18 %	98.79 %	+3.61 %	⚡ Oui
Taux doublons exacts	1.94 %	0.00 %	-1.94 %	⚡ Oui
Taux dates invalides	0.98 %	0.00 %	-0.98 %	—
Taux incohérences temporelles	3.79 %	0.00 %	-3.79 %	⚡ Oui
Taux Reporting Area non conformes	1.04 %	0.00 %	-1.04 %	⚡ Oui

4.2 Indicateurs avec évolution significative (|Δ| ≥ 1 %)

- ↑ Complétude Neighborhood : 93,18 % → 100,00 % (+6,82 pts) — amélioration majeure
- ↑ Complétude Crime : 95,00 % → 100,00 % (+5,00 pts) — toutes les lignes ont un type de crime
- ↑ Unicité File Number : 95,18 % → 98,79 % (+3,61 pts) — doublons supprimés
- ↓ Incohérences temporelles : 3,79 % → 0,00 % (-3,79 pts) — intégrité temporelle assurée
- ↓ Doublons exacts : 1,94 % → 0,00 % (-1,94 pts) — dataset dédupliqué
- ↓ Reporting Area non conformes : 1,04 % → 0,00 % (-1,04 pts)

Note : l'unicité de File Number reste à 98,79 % (non 100 %) car certains numéros de dossier sont partagés entre plusieurs crimes distincts — probablement des dossiers multi-infractions. Ce cas ne peut être résolu sans règle métier complémentaire.

ABRAURE Axel — 2025-2026

5. Cartographie — Choroplèthe des crimes par quartier

5.1 Agrégation des crimes par quartier

Quartier	Nombre de crimes	% du total
Cambridgeport	1 391	16.6 %
East Cambridge	1 187	14.2 %
Mid-Cambridge	952	11.4 %
North Cambridge	932	11.1 %
Area 4	920	11.0 %
Riverside	908	10.8 %
West Cambridge	889	10.6 %
Peabody	598	7.1 %
Inman/Harrington	570	6.8 %
Agassiz / Highlands / MIT / Strawberry Hill	~22 %	répartis
TOTAL	8 369	100 %

5.2 Carte choroplèthe

La carte ci-dessous représente le nombre de crimes par quartier (du vert — peu de crimes — au rouge — beaucoup de crimes). Une version interactive avec tooltip est disponible dans output/map.html.

ABRAURE Axel — 2025-2026

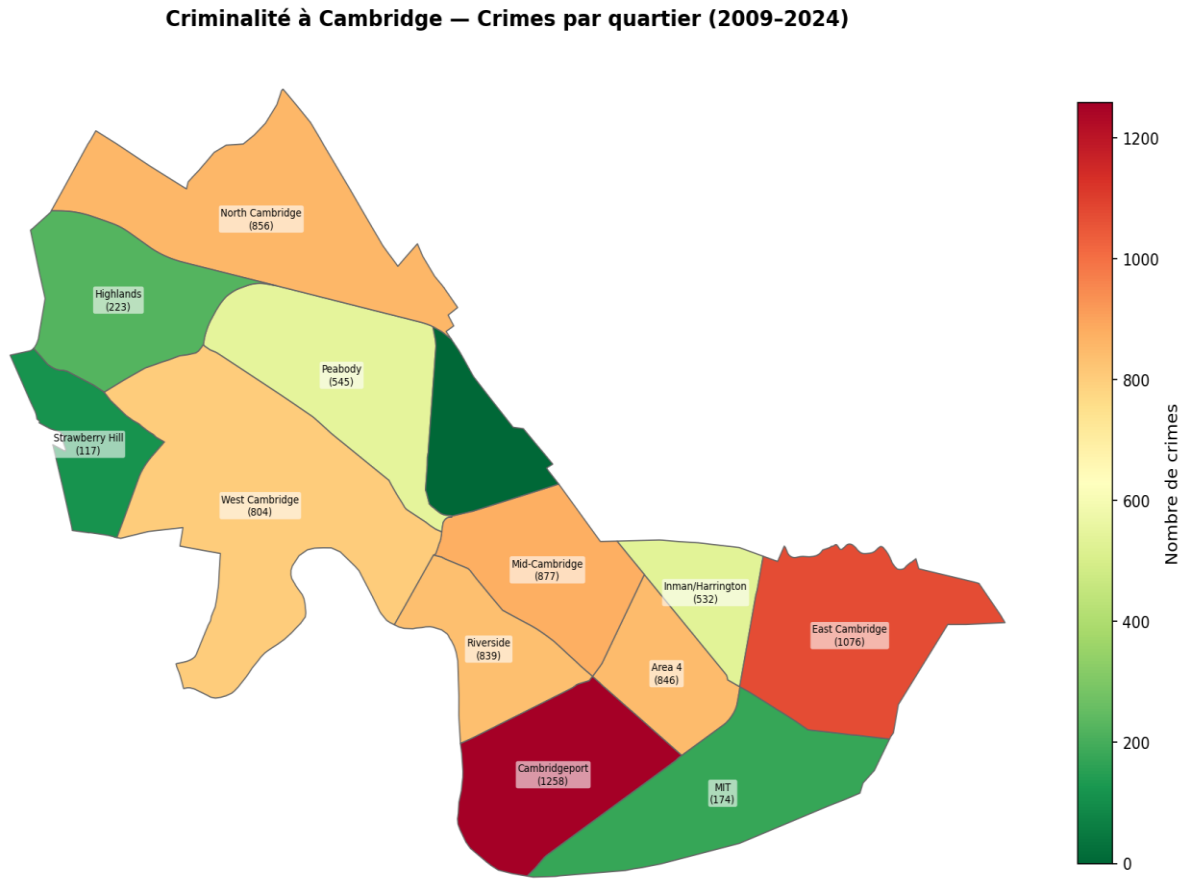

5.3 Répartition par quartier

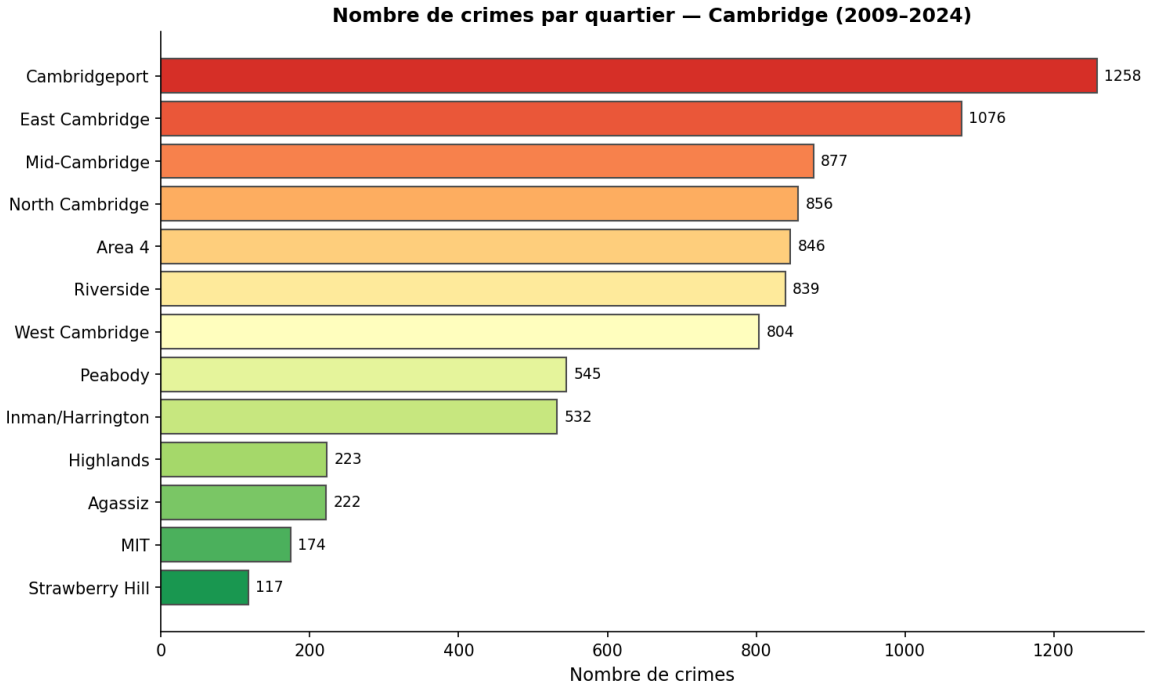

5.4 Analyse et limites de l'indicateur

ABRAURE Axel — 2025-2026

Pourquoi « quartier le plus dangereux » peut-il être trompeur avec un volume brut ?

Un volume brut de crimes ne tient pas compte de la superficie ni de la population du quartier. Un quartier densément peuplé ou très étendu accumulera mécaniquement plus de signalements qu'un quartier résidentiel calme, sans que le risque per capita soit supérieur.

Pour comparer équitablement les quartiers, il faudrait un taux de criminalité ramené à la population (crimes / 1 000 habitants) ou à la superficie (crimes / km²).

ABRAURE Axel — 2025-2026

Annexe — Structure du projet

Fichier / Dossier	Rôle
src/main.py	Pipeline principale — exécute les 5 sections en séquence
src/profiling.py	Section 1 — profilage, dictionnaire des données
src/quality.py	Section 2 — 8 indicateurs de qualité + seuils
src/treatment.py	Section 3 — 6 règles de nettoyage + enrichissement
src/mapping.py	Section 5 — carte choroplèthe Folium
tests/test_quality.py	20 tests pytest — toutes règles couvertes
data/crime_reports_broken.csv	Dataset brut d'entrée
data/BOUNDARY_CDDNeighborhoods.geojson	Référentiel géographique des quartiers
output/crime_reports_clean.csv	Dataset nettoyé (8 369 lignes)
output/map.html	Carte choroplèthe interactive
logs/app.log	Journalisation de toutes les étapes du traitement
requirements.txt	Dépendances Python du projet
README.md	Documentation complète du projet

Exécution

```
python -m venv .venv && .venv\Scripts\activate
pip install -r requirements.txt
cd src && python main.py
pytest tests/ -v
```


ABRAURE Axel — 2025-2026